

AULA 7 - CLASSIFICAÇÃO - PT1

#BootcampMIA2022 #SomosMIA



Quem somos?



Priscilla Koch Wagner

Data Scientist na Neuralmed

- Mestra em Sistemas de Informação pela USP com pesquisa em inteligência artificial e área de aplicação em bioinformática
- Co-fundadora da MIA



priscillaKW



priscilla-wagner



Quem somos?



Jéssica dos Santos

Head de Dados na NeuralMed

- Mestra em Sistemas de Informação pela USP com pesquisa em inteligência artificial e área de aplicação em saúde
- Co-fundadora da MIA



jessica-santos



jessica-santos-oliveira



Uma inspiração...

"Estamos inundando pessoas com informações. Precisamos alimentá-lo através de um processador. Um humano deve transformar a informação em inteligência ou conhecimento."

(Grace Hopper)

Nos mandem suas dúvidas!!!

**Estamos pensando em fazer uma aula de dúvidas,
o que acham??**



Nos mandem suas dúvidas!!!

Estamos pensando em fazer uma aula de dúvidas, o que acham??

Se tiverem dúvidas preencham o formulário que vamos mandar pra vocês ou mandem suas perguntas no canal de aulas do discord!

Queremos ajudar com suas dúvidas, mas precisamos saber se vocês gostariam! :)

Nos mandem suas dúvidas!!!

**Estamos pensando em fazer uma aula de dúvidas,
o que acham??**



Falem com a gente!!

Teremos prêmios \o/

As empresas parceiras do Bootcamp vão dar alguns prêmios pra vocês!!

Globo - 9 Cursos DSA → para os grupos melhores colocados no desafio final

Americanas - Cursos (a definir) → para as mais participativas

Regra: pelo menos 30% de feedbacks preenchidos (cada feedback que você enviar aumenta suas chances) + envio de exercícios


Microsoft - certificação para todas que tiverem mais de 75% de presença (ou 60% com justificativa)

Recapitulando:
**O que vocês
aprenderam na
última aula?**




Regressão!

Em que situações vocês a usariam?



**E se tivéssemos que
predizer se um imóvel
vai ser vendido ou não?**

Poderíamos fazer uma
regressão nesse caso?



Predizer se um imóvel será vendido ou não, assim como predirer...


- ▷ se um e-mail é spam ou não
- ▷ a raça de um cachorro com base em uma foto

Chihuahua or Muffin?



São problemas de
CLASSIFICAÇÃO!

Classificação vs regressão




Classificação de dados

Na tarefa de classificação, o objetivo é que nosso algoritmo seja capaz de indicar a qual **classe** um exemplo pertence com base em um conjunto de dados já classificado.

Atributos (features)			Classe (target/label)
Idade	Renda	Possui dívidas	Cartão de crédito aprovado
18	1000	Não	Não
25	2500	Sim	Sim
50	4500	Sim	Não
42	10000	Não	Não
33	6000	Não	Sim
27	5700	Não	Não

Tipos de problemas

Classificação binária



É cachorro

Não é cachorro

Classificação multiclasse



Cachorro

Gato

Coelho

Papagaio

Cavalo

...

Classificação multilabel



Cachorro

Gato

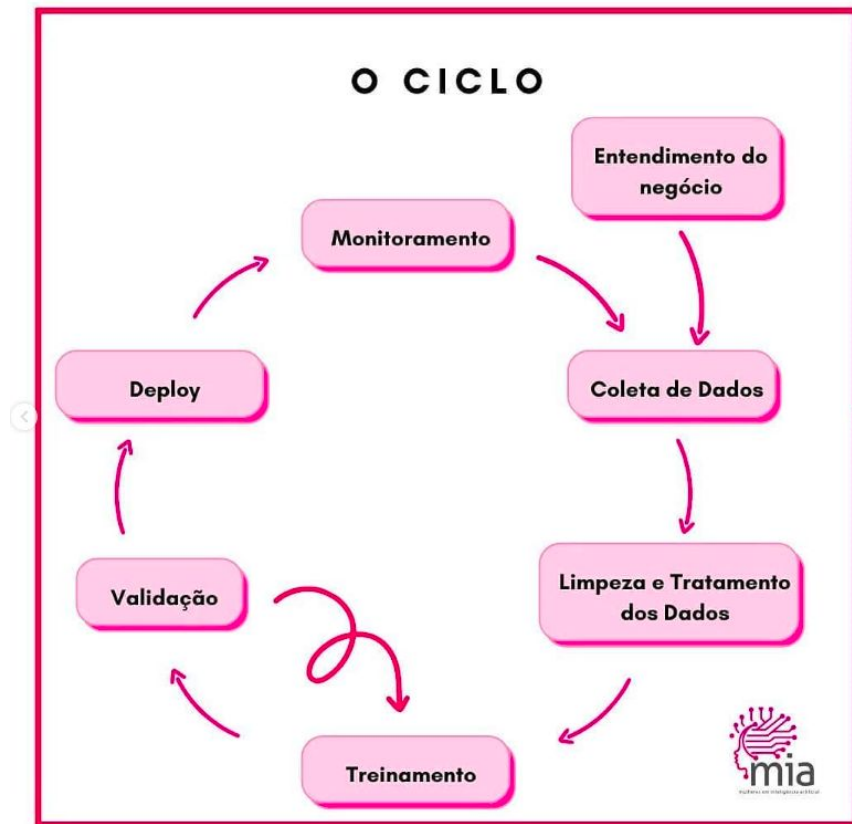
Coelho

Papagaio

Cavalo

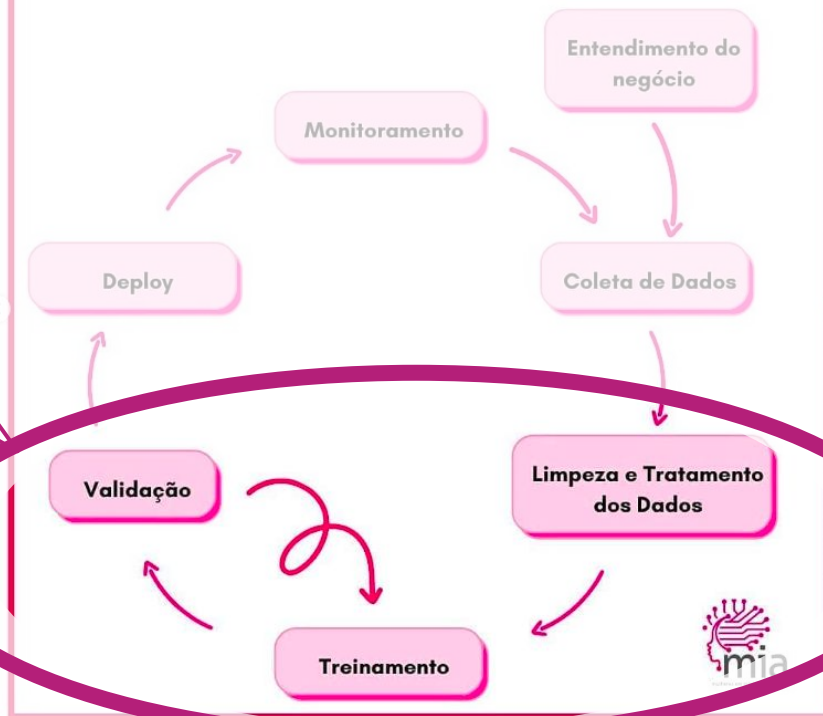
...

Ciclo de vida



Ciclo de vida

O CICLO



Vamos focar nessas partes nessa e nas próximas aulas

Pré-processamento dos dados

Essa etapa é **MUITO** importante (e é a que demora mais tempo)!!!
É nela em que iremos preparar o conjunto de dados que será utilizado para treinar o modelo

Análise exploratória

- ▷ Entender o conjunto de dados
- ▷ Identificar quais atributos fazem sentido
- ▷ Identificar atributos que podem ser criados
- ▷ Identificar a necessidade de se fazer transformações nos dados

Feature engineering

- ▷ Preparar o conjunto de dados de maneira apropriada para o problema e para o algoritmo que será utilizado
- ▷ Nela, lidamos com
 - Dados faltantes
 - Outliers
 - Transformações de atributos categóricos
 - Etc.

Pré-processamento dos dados

Essa etapa é **MUITO** importante (e é a que demora mais tempo)!!!
É nela em que se prepara o conjunto de dados que será utilizado para treinar o modelo.

Análise

Vamos estudar essa parte mais a fundo

- ▷ Entender o problema
- ▷ Identificar o sentido
- ▷ Identificar atributos que podem ser criados
- ▷ Identificar a necessidade de se fazer transformações nos dados

Feature engineering

- ▷ Preparar o conjunto de dados de maneira apropriada para o problema e para o algoritmo que será utilizado
- ▷ Nela, lidamos com
 - Dados faltantes
 - Outliers
 - Transformações de atributos categóricos
 - Etc.

Outra forma
de falar
“variável”

Feature Engineering

Existem vários tratamentos nos dados que precisam ser feitos antes que ele possa ser usado para o treinamento de um modelo:

- ▷ Tratamento de missing values
- ▷ Remoção de outliers
- ▷ Normalização de dados
- ▷ Seleção de features
- ▷ Balanceamento de Dados
- ▷ Viés Amostral (Features Bias/Sample Bias/Prejudice Bias)

Feature Engineering

Existem vários tratamentos nos dados que precisam ser feitos antes que ele possa ser usado para o treinamento de um modelo:

- ▷ **Tratamento de missing values**
- ▷ **Remoção de outliers**
- ▷ **Normalização de dados**
- ▷ Seleção de features
- ▷ Balanceamento de Dados
- ▷ Viés Amostral (Features Bias/Sample Bias/Prejudice Bias)


Vistos durante as aulas anteriores

Seleção de Features

Por que fazer?

A maldição da dimensionalidade diz que a quantidade de variáveis que você tem impacta diretamente na performance do seu classificador.

Excesso de variáveis irrelevantes podem gerar sujeira, fazendo com que dados parecidos fiquem distantes no espaço.



Seleção de Features

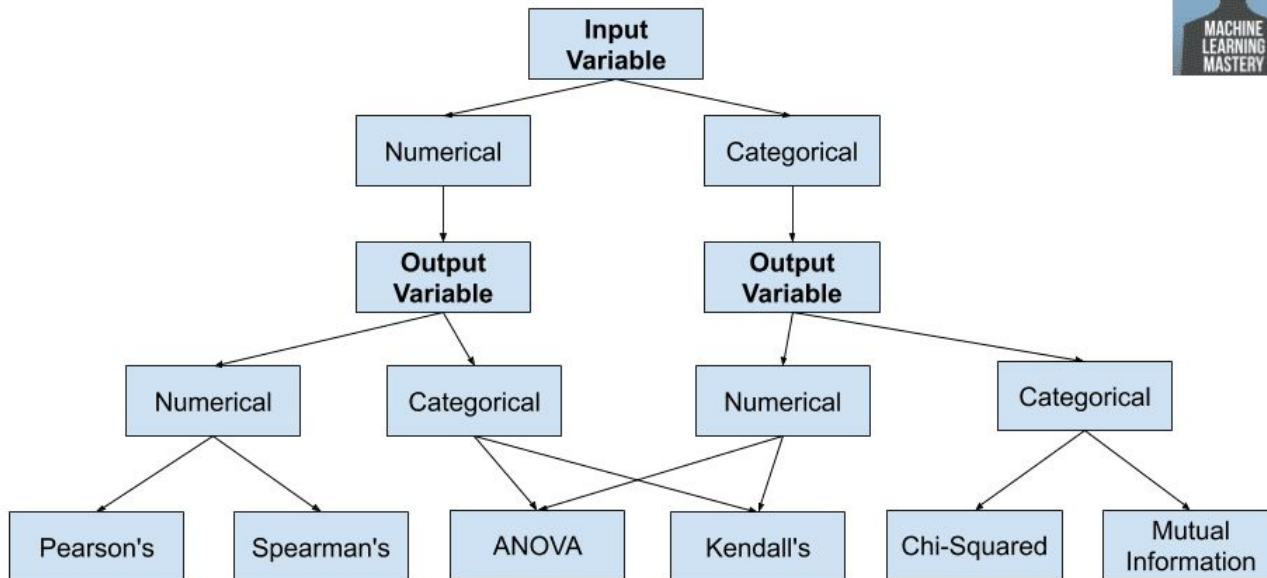
Tipos de técnicas:

- Filtros: São aplicadas técnicas para selecionar as características **antes** de treinar a classificação. Podem ser por métodos estatísticos como análise de correlação ou **Feature Importance**.
- Wrapper: O próprio classificador é utilizado para selecionar as características de acordo com o desempenho de cada conjunto de seleção.
- Embutido: a seleção é feita pelo classificador. Ex.: Random Forest

Seleção de Features

Técnicas Estatísticas:

How to Choose a Feature Selection Method



Feature Bias ou Viés de Atributos


Twitter exclui algoritmo de recorte de imagem por viés contra minorias

Segundo a empresa, a ferramenta favorecia usuários homens e brancos em vez de negros e mulheres, além de ter o que chamaram de "olhar masculino", concentrando o recorte no peito ou nas pernas de mulheres.


Por G1
19/05/2021 20h05 - Atualizado há 11 meses



help does twitter only focus on the white dude??



9:28 AM · Sep 21, 2020 · Twitter Web App



Home > Internet > Redes sociais

Instagram vai revisar algoritmo para garantir tratamento igualitário a minorias

Por Rafael Arbulu | 16 de Junho de 2020 às 10h42

Divulgação/m



Tudo sobre Instagram

VER MAIS

O [Instagram](#) vai revisar o seu próprio algoritmo para aprimorá-lo e trazer recomendações de conteúdo que tratem minorias de forma mais igualitária dentro da plataforma. O anúncio foi feito pelo CEO da empresa, Adam Mosseri, em seu perfil oficial no [Twitter](#). Segundo o executivo, a iniciativa é para garantir que as públicas representadas

Feature Bias ou Viés de Atributos

Outros exemplos:

- Os homens são menos propensos do que as mulheres a relatar uma história familiar de câncer, mesmo que exista; essa diferença pode levar a uma **subestimação do risco para o sexo masculino**.
- O uso de prisões prévias em modelos de reincidência criminal tem sido criticado porque as prisões não refletem os crimes subjacentes de maneira uniforme. Por exemplo, quando há **diferenças raciais na detecção de crimes** ou no uso de prisões versus advertências, um modelo pode **superestimar os riscos para alguns grupos**
- Datasets de detecção de algumas doenças podem ter **baixa representatividade de grupos sub representados**. Um modelo treinado com esses dados pode não funcionar bem para toda a população

Feature Bias ou Viés de Atributos

O que podemos fazer para evitar esses viés:

- Idealmente: usar dados que sejam adequadamente representativos e grandes o suficiente para neutralizar possíveis problemas de viés.
- Modificar os dados corrigindo o viés: ex.: balanceando as classes entre os grupos analisados.
- Criar modelos separados para cada grupo
- Testar e validar bem o seu modelo com métricas adequadas
- Utilizar técnicas de interpretabilidade para entender e garantir que o seu modelo não está agindo de forma enviesada
- Monitorar o seu modelo ao longo do tempo para garantir que não está ocorrendo nenhum viés

Feature Bias ou Viés de Atributos

O que podemos fazer para evitar esses viés:

- Idealmente: usar dados que sejam adequadamente representativos e grandes o suficiente para neutralizar possíveis problemas de viés.
- Modificar os dados corrigindo o viés: ex.: balanceando as classes entre os grupos analisados.
- Criar modelos separados para cada grupo
- Testar e validar bem o seu modelo com métricas adequadas
- Utilizar técnicas de interpretabilidade para entender e garantir que o seu modelo não está agindo de forma enviesada
- Monitorar o seu modelo ao longo do tempo para garantir que não está ocorrendo nenhum viés

Veremos esses
em breve

Sugestão para mais aprendizado:


Curso de Ética em IA do Kaggle:

<https://www.kaggle.com/learn/intro-to-ai-ethics>





Balanceamento das classes

- Ex: Modelo para detectar doença de chron, nos dados de treinos menos de 1% é positivo. Resultado??
- Modelo treinou que todo mundo é negativo, com isso, **acurácia é de 99%**, já que só erra 1% das vezes.



Balanceamento das classes

Como corrigir?



e/ou uso de pesos: class weights

Além de analisar com métricas corretas**

Dados prontos!!

Vamos ao nosso primeiro
modelo!!



Que modelo escolher?

Existem diversos algoritmos de Machine Learning para resolvermos problemas de classificação

Naive Bayes

Redes neurais

Árvore de decisão

KNN

SVM

Regressão logística

KNN - K Nearest Neighbors

Um dos modelos mais simples que existem!

Não existe, de fato, um treinamento!!

Como assim não existe treinamento?

Seu aprendizado é, na realidade, apenas o armazenamento dos dados de treinamento!



KNN - K Nearest Neighbors

A predição é feita comparando o novo dado com os **k** dados de treino mais próximos.

Então, o dado novo é classificado com a classe mais comum entre seus “vizinhos”.

KNN - K Nearest Neighbors

Como sei quais os “vizinhos”?


É definida por uma métrica de distância.
A mais comum é a distância Euclidiana:

$$X_1 = (x_{11}, x_{12}, \dots, x_{1n})$$

$$X_2 = (x_{21}, x_{22}, \dots, x_{2n})$$

$$\text{dist}(X_1, X_2) = \sqrt{\sum_{i=1}^n (x_{1i} - x_{2i})^2}$$

Essa distância é calculada entre o dado novo e todos os dados do conjunto de treinamento.




KNN - K Nearest Neighbors

Selecionar os k “vizinhos”: aqueles em que a distância foi menor!

k=1 : Pertence a classe de quadrados

k=3 : Pertence a classe de triângulos

k=7 : Pertence a classe de quadrados



KNN - K Nearest Neighbors

Mas se pode mudar de classe dependendo de k , como definir k ?



Testando vários valores para k !

Usamos o conjunto de teste para avaliar o erro do modelo*. O valor de **k** que der o menor erro é selecionado!

**(vamos ver como calcular o erro e acerto do modelo mais pra frente)*

KNN - K Nearest Neighbors



- Limão
- Laranja

KNN - K Nearest Neighbors

Melhorias:

- Atribuir pesos nas features
- Remover dados com ruído do conjunto de treinamento
- Usar outras métricas de distância
- Calcular a distância com menos features

Vantagens:

- Simples de entender e explicar
- Poucos parâmetros (k e métrica de distância)

Desvantagens:

- Muito lento para predição quando o conjunto de treinamento é grande

Agora que já treinamos o modelo, como saber se ele está bom?



A métrica mais simples e mais conhecida é a **ACURÁCIA**

Acurácia é a proporção de exemplos que foram preditos corretamente pelo modelo

Como já vimos, nem sempre a acurácia é a melhor métrica de avaliação...

É o mesmo cenário do exemplo de detectar doença de chron, onde o dataset está **desbalanceado**.

Um outro exemplo: prever se uma transação seria fraudulenta ou não. Vamos supor que a proporção de fraudes seja de 3%...

Vocês lembram porque?

...Se o modelo previsse todos os exemplos como pertencentes a classe majoritária (não é fraude), teríamos uma **acurácia de 97%**!

Apesar da acurácia alta, esse não seria um bom modelo!



Quais outras métricas de avaliação podemos usar?

Matriz de confusão

Class real

	Not Mortality		
0	<div> <div>TN</div> <div>Mortality</div> </div>	<div>54</div> <div>2</div>	<div>4</div> <div>14</div>
1	<div>FN</div>	<div>Not Mortality</div>	<div>Mortality</div>
	0		1
	<div>Classe prevista</div> <div>Classe prevista</div>		

TP (True Positive): são os exemplos que eram da classe positiva e o modelo predisse corretamente

TN (True Negative): são os exemplos que eram da classe negativa e o modelo predisse corretamente

FN (False Negative): são os exemplos que eram da classe negativa, mas o modelo predisse que era da classe positiva

FP (False Positive): são os exemplos que eram da classe positiva, mas o modelo predisse que era da classe negativa



Quais outras métricas de avaliação podemos usar?

O legal da matriz de confusão é que, a partir dela, podemos tirar outras métricas como...

Classe real	0	TN	FP
	1	FN	TP
		0	1
		Classe prevista	

Acurácia

De todas as predições que o modelo fez, quantos ele acertou?

$$\frac{TP + TN}{TP + FP + FN + TN}$$

Quais outras métricas de avaliação podemos usar?

O legal da matriz de confusão é que, a partir dela, podemos tirar outras métricas como...

Classe real

Not Mortality	54	4
Mortality	2	14
	Not Mortality	Mortality

Classe prevista

Acurácia

De todas as predições que o modelo fez, quantos ele acertou?

$$\frac{54 + 14}{54 + 2 + 4 + 14} = 0.92$$

Quais outras métricas de avaliação podemos usar?

O legal da matriz de confusão é que, a partir dela, podemos tirar outras métricas como...

Classe real	0	TN	FP
	1	FN	TP
		0	1
		Classe prevista	

Precisão

De todos os exemplos que o modelo classificou como sendo da classe positiva, quais realmente eram?

$$\frac{TP}{TP + FP}$$

Quais outras métricas de avaliação podemos usar?

O legal da matriz de confusão é que, a partir dela, podemos tirar outras métricas como...

Classe real

Not Mortality	54	4
Mortality	2	14
	Not Mortality	Mortality

Classe prevista

Precisão

De todos os exemplos que o modelo classificou como sendo da classe positiva, quais realmente eram?

$$\frac{14}{14 + 4} = 0.78$$

Quais outras métricas de avaliação podemos usar?

O legal da matriz de confusão é que, a partir dela, podemos tirar outras métricas como...

Classe real	0	TN	FP
	1	FN	TP
		0	1
		Classe prevista	

Recall (sensibilidade)

De todos os exemplos da classe positiva, quantos o modelo classificou corretamente?

$$\frac{TP}{TP + FN}$$

Quais outras métricas de avaliação podemos usar?

O legal da matriz de confusão é que, a partir dela, podemos tirar outras métricas como...

Classe real

Not Mortality	54	4
Mortality	2	14
	Not Mortality	Mortality

Classe prevista

Recall (sensibilidade)

De todos os exemplos da classe positiva, quantos o modelo classificou corretamente?

$$\frac{14}{14 + 2} = 0.88$$

Quais outras métricas de avaliação podemos usar?

O legal da matriz de confusão é que, a partir dela, podemos tirar outras métricas como...

Classe real	0	TN	FP
	1	FN	TP
		0	1
		Classe prevista	

Especificidade

De todos os exemplos da classe negativa, quantos o modelo classificou corretamente?

$$\frac{TN}{TN + FP}$$

Quais outras métricas de avaliação podemos usar?

O legal da matriz de confusão é que, a partir dela, podemos tirar outras métricas como...

Classe real

Not Mortality	54	4
Mortality	2	14
	Not Mortality	Mortality

Classe prevista

Especificidade

De todos os exemplos da classe negativa, quantos o modelo classificou corretamente?

$$\frac{54}{54 + 4} = 0.93$$

Nossa quanta métrica...

Podemos simplificar a precisão e o recall em uma única métrica:

F1-score

Combina precisão e recall em uma métrica única que indique qualidade geral do modelo. Funciona bem inclusive em dados desbalanceados.

É calculada a partir da média harmônica entre precisão e recall.

$$2 * \frac{\text{Precisão} * \text{recall}}{\text{Precisão} + \text{recall}}$$

$$2 * \frac{0.78 * 0.88}{0.78 + 0.88} = 0.82$$

Outra métrica importante!




ROC curve

É um gráfico que mostra o desempenho de um modelo de classificação em todos os thresholds.

Uma curva ROC é definida pela Taxa de True Positive vs. Taxa de False Positive.

Usa as probabilidades retornadas pelos modelos. A maioria dos modelos nos dá uma probabilidade dos exemplos serem de cada uma das classes. O threshold é o “corte” que definimos para dizer se é da classe positiva ou negativa.




Tá, mas qual a métrica que eu tiro do gráfico?

AUC-ROC (Area Under the ROC Curve)

Mede toda a área abaixo de toda a curva ROC.


- AUC mede quão bem as previsões são classificadas, em vez de seus valores absolutos.
- AUC mede a qualidade das previsões do modelo, independentemente do threshold escolhido.




Tá, mas qual a métrica que eu tiro do gráfico?

AUC-ROC (Area Under the ROC Curve)

AUC varia em valor de 0 a 1. Um modelo cujas previsões estão 100% erradas tem uma AUC de 0; aquele cujas previsões estão 100% corretas tem uma AUC de 1.



Overlap = How well the model separates Negatives and Positives



Qual conjunto de dados eu uso para aplicar e avaliar as métricas?


O conjunto de **TESTE!!!**

Mas precisamos ficar atentas nas métricas dos outros conjuntos também!




Existem outras formas de validar o modelo além de apenas o conjunto de teste, como a Validação Cruzada.
Mas não teremos tempo de falar sobre ela hoje!

Underfitting vs Overfitting



Underfitting



Desired




Overfitting

Underfitting: quando o modelo não consegue aprender os dados de treinamento nem generalizar para novos dados. Modelo muito simples!

Overfitting: quando o modelo “decora” muito bem os dados de treinamento, mas não generaliza para novos dados. Modelo muito complexo!

Underfitting vs Overfitting



Underfitting: taxa de erro alta no treino e no teste. (viés alto)

Overfitting: taxa de erro baixa no treino, mas alta no teste. (variância alta)

Solução ótima: taxa de erro baixa no treino e no teste.

Underfitting vs Overfitting

O que fazer nesses casos?

- Usar um modelo mais simples (para overfitting) ou mais complexo (para underfitting).
- Adicionar (para underfitting) ou remover (para overfitting) features
- Adicionar mais dados (para overfitting) pode ajudar também!!

Vamos praticar!!!



Material Complementar

- [Fundamentos de Feature Engineering](#)
- [Notebook Kaggle com exemplos de diferentes métodos de seleção](#)
- [Comprehensive Guide - Feature Selection](#)
- [Tutorial de Seleção do Sklearn](#)
- [Curso sobre ética em IA](#)
- [Implementação de algoritmos de classificação no sklearn](#)
- [Métricas de avaliação: precisão, recall, especificidade e f1-score](#)
- [ROC-curve e AUC](#)
- [Overfitting e Underfitting](#)

Vamos preencher o formulário de feedback???





Nossos contatos



mulheres.em.ia@gmail.com



mulheres-em-ia



@mulheres.em.ia



@mulheres.em.ia



@MulheresemInteligenciaArtificial




Canal: Mulheres em IA

Linktree

<https://linktr.ee/mulheres.em.ia>

Grupo Telegram para Mulheres

https://t.me/mulheres_em_ia



Muito obrigada!

Dúvidas? Podem nos procurar! 🙄